

Regresión Lineal Múltiple

Víctor Aceña - Isaac Martín

DSLAB

2025-09-11



El modelo de regresión lineal múltiple constituye la **extensión natural y más potente** del modelo simple.

Diferencias clave:

Regresión Simple:

- Una variable respuesta
- Un único predictor
- Relación bivariada

Regresión Múltiple:

- Una variable respuesta
- **Múltiples predictores**
- Relación multivariada

Capacidades únicas:

- **Modelar simultáneamente** el efecto de múltiples variables predictoras
- **Interpretación de coeficientes** en presencia de otros predictores
- **Diagnóstico específico** del modelo múltiple
- Manejo de la **multicolinealidad**

1. **Formular y estimar** modelos de regresión lineal múltiple, comprendiendo las diferencias clave respecto al caso simple
2. **Interpretar coeficientes** en el contexto multivariante, entendiendo el concepto de *ceteris paribus*
3. **Realizar inferencia estadística** construyendo intervalos de confianza y contrastes de hipótesis
4. **Evaluar la calidad del ajuste** usando medidas como R^2 , R^2 ajustado y descomposición ANOVA
5. **Diagnosticar el modelo múltiple** aplicando técnicas específicas como gráficos CPR
6. **Identificar y tratar la multicolinealidad** usando el VIF como herramienta de diagnóstico
7. **Realizar predicciones** distinguiendo entre intervalos de confianza e intervalos de predicción

Para n observaciones y p variables predictoras, el **modelo poblacional** postula:

$$Y_i = \beta_0 + \beta_1 X_{i1} + \beta_2 X_{i2} + \dots + \beta_p X_{ip} + \varepsilon_i, \quad i = 1, \dots, n$$

Componentes:

- Y_i : i -ésima variable respuesta aleatoria
- X_{ij} : i -ésima variable predictora aleatoria del j -ésimo predictor
- ε_i : término de error aleatorio
- $\beta_0, \beta_1, \dots, \beta_p$: coeficientes poblacionales verdaderos pero desconocidos

Características clave:

- Relación **lineal en los parámetros**
- Los errores son **no observables**
- Los parámetros son **constantes poblacionales**

En la práctica, trabajamos con **datos observados** y estimamos el modelo:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{i1} + \hat{\beta}_2 x_{i2} + \cdots + \hat{\beta}_p x_{ip}, \quad i = 1, \dots, n$$

Componentes:

- \hat{y}_i : i -ésima predicción
- x_{ij} : i -ésima observación del j -ésimo predictor
- $\hat{\beta}_j$: coeficientes estimados

Interpretación clave de $\hat{\beta}_j$:

El cambio estimado en la media de Y ante un cambio de una unidad en X_j , **manteniendo constantes todas las demás variables predictoras**.

Este principio se conoce como ***ceteris paribus*** (“lo demás constante”)

Modelo poblacional:

$$\mathbf{Y} = \tilde{X}\beta + \varepsilon$$

$$\mathbf{Y} = \begin{bmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{bmatrix}, \quad \tilde{X} = \begin{bmatrix} 1 & X_{11} & X_{12} & \cdots & X_{1p} \\ 1 & X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix}$$

$$\beta = \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{bmatrix}, \quad \varepsilon = \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Nota: \tilde{X} contiene variables aleatorias (mayúsculas X_{ij})

Modelo muestral:

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\boldsymbol{\beta}}$$

$$\hat{\mathbf{y}} = \begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \vdots \\ \hat{y}_n \end{bmatrix}, \quad \mathbf{X} = \begin{bmatrix} 1 & x_{11} & x_{12} & \cdots & x_{1p} \\ 1 & x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}, \quad \hat{\boldsymbol{\beta}} = \begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \vdots \\ \hat{\beta}_p \end{bmatrix}$$

Observaciones:

- \mathbf{X} contiene datos observados (minúsculas x_{ij})
- \mathbf{X} y $\tilde{\mathbf{X}}$ son matrices de dimensión $n \times (p + 1)$
- La primera columna de unos corresponde al intercepto β_0

Supuestos del Modelo Lineal Múltiple

Condiciones de Gauss-Markov:

1. **Linealidad en los parámetros:** El modelo $E[\mathbf{Y}|\tilde{X}] = \tilde{X}\beta$ está bien especificado
2. **Exogeneidad:** Los errores tienen media cero: $E[\varepsilon|\tilde{X}] = \mathbf{0}$
3. **Homocedasticidad e independencia:** $\text{Var}(\varepsilon|\tilde{X}) = \sigma^2\mathbf{I}_n$
4. **Ausencia de multicolinealidad perfecta:** \mathbf{X} tiene rango completo ($p + 1$)
5. **Normalidad (para inferencia):** $\varepsilon \sim N(\mathbf{0}, \sigma^2\mathbf{I}_n)$

Implicación: Estos supuestos garantizan que los estimadores MCO sean **insesgados, consistentes y eficientes**

Principio: Minimizar la discrepancia entre valores observados y predichos

Función objetivo:

$$S(\beta) = \sum_{i=1}^n e_i^2 = \mathbf{e}^T \mathbf{e} = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta)$$

¿Por qué cuadrados?

- Los residuos positivos y negativos no se cancelan
- Se penalizan más fuertemente los errores grandes
- Facilita el tratamiento matemático

Resultado: MCO minimiza la **Suma de los Cuadrados de los Residuos** (SSR)

Expandiendo la función objetivo:

$$S(\beta) = \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T (\mathbf{X}^T \mathbf{X}) \beta$$

Derivando respecto a β :

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}^T \mathbf{y} + 2(\mathbf{X}^T \mathbf{X}) \beta$$

Igualando a cero:

$$-2\mathbf{X}^T \mathbf{y} + 2(\mathbf{X}^T \mathbf{X}) \hat{\beta} = \mathbf{0}$$

Ecuaciones Normales:

$$(\mathbf{X}^T \mathbf{X}) \hat{\beta} = \mathbf{X}^T \mathbf{y}$$

Solución única:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

Condición necesaria: La matriz $(\mathbf{X}^T \mathbf{X})$ debe ser invertible

¿Cuándo es invertible?

- Cuando \mathbf{X} tiene rango completo $(p + 1)$
- Cuando las columnas de \mathbf{X} son linealmente independientes
- Cuando no hay multicolinealidad perfecta

Propiedades de $(\mathbf{X}^T \mathbf{X})$:

- Dimensión: $(p + 1) \times (p + 1)$
- Simétrica
- Definida positiva (si es invertible)

Bajo los supuestos de Gauss-Markov:

1. **Insesgados:** $E[\hat{\beta}] = \beta$
2. **Eficientes:** Varianza mínima entre todos los estimadores lineales insesgados
3. **Consistentes:** $\hat{\beta} \xrightarrow{p} \beta$ cuando $n \rightarrow \infty$

Matriz de varianza-covarianza:

$$\text{Var}(\hat{\beta}) = \sigma^2(\mathbf{X}^T\mathbf{X})^{-1}$$

Bajo normalidad adicional:

$$\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}^T\mathbf{X})^{-1})$$

Estimador insesgado de σ^2 :

$$\hat{\sigma}^2 = \frac{\text{SSE}}{n - p - 1} = \frac{\sum_{i=1}^n e_i^2}{n - p - 1} = \frac{\mathbf{e}^T \mathbf{e}}{n - p - 1}$$

Grados de libertad: $n - p - 1$

- n : número de observaciones
- $p + 1$: número de parámetros estimados

Distribución:

$$\frac{(n - p - 1)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-p-1}^2$$

Error estándar de los coeficientes:

$$\hat{\sigma}_{\beta_j} = \hat{\sigma} \sqrt{(\mathbf{X}^T \mathbf{X})_{jj}^{-1}}$$

Datos: Precios de viviendas basados en características

Variables predictoras:

- superficie: Metros cuadrados
- habitaciones: Número de habitaciones
- antigüedad: Años de antigüedad
- distancia_centro: Distancia al centro (km)
- garaje: Presencia de garaje (Sí/No)

Coeficiente de regresión parcial:

$$\beta_j = \frac{\partial E[Y|\tilde{X}]}{\partial X_j}$$

Interpretación: β_j representa el cambio esperado en Y por una unidad de cambio en X_j , **manteniendo todas las demás variables constantes**

Diferencia crucial:

Regresión Simple:

- Efecto **total** (directo + indirecto)
- Puede estar **confundido**
- $\hat{\beta}_j$ captura toda la asociación

Regresión Múltiple:

- Efecto **puro** o **parcial**
- **Controla** por otras variables
- Interpretación más **causal**

Concepto clave: El coeficiente proviene de una regresión entre residuos

	Estimate	Std. Error
(Intercept)	53750.9705	6666.70624
superficie	1171.7780	47.28087
habitaciones	15072.3104	1303.41715
antigüedad	-744.5896	75.42075
distancia_centro	-2028.2715	164.87756
garajeSí	25829.4317	2349.44285

Interpretación *ceteris paribus*:

- **Superficie** (+1,172 €/m²): Cada m² adicional incrementa el precio
- **Habitaciones** (+15,072 €): Cada habitación adicional aumenta el precio
- **Antigüedad** (-745 €/año): Cada año de antigüedad reduce el precio
- **Distancia centro** (-2,028 €/km): Cada km más lejos del centro reduce el precio
- **Garaje** (+25,829 €): Tener garaje incrementa el precio

Descomposición ANOVA:

$$SST = SSR + SSE$$

Donde:

- **SST** (Sum of Squares Total): $\sum_{i=1}^n (y_i - \bar{y})^2$
- **SSR** (Sum of Squares Regression): $\sum_{i=1}^n (\hat{y}_i - \bar{y})^2$
- **SSE** (Sum of Squares Error): $\sum_{i=1}^n (y_i - \hat{y}_i)^2$

Interpretación:

- **SST**: Variabilidad total en los datos
- **SSR**: Variabilidad explicada por el modelo
- **SSE**: Variabilidad no explicada (residual)

R-cuadrado:

$$R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$$

Interpretación:

- Proporción de la variabilidad en Y explicada por el modelo
- Rango: $0 \leq R^2 \leq 1$
- $R^2 = 0$: El modelo no explica nada
- $R^2 = 1$: El modelo explica toda la variabilidad

Problema: R^2 siempre aumenta al añadir variables (incluso irrelevantes)

En regresión múltiple: R^2 es el cuadrado de la correlación entre y y \hat{y}

R-cuadrado ajustado:

$$R_{\text{adj}}^2 = 1 - \frac{\text{SSE}/(n - p - 1)}{\text{SST}/(n - 1)} = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

Ventajas:

- **Penaliza** la inclusión de variables irrelevantes
- **Puede decrecer** si una variable no aporta información suficiente
- Mejor para **comparar modelos** con diferente número de predictores

Criterio de decisión:

- Si R_{adj}^2 aumenta al añadir una variable \rightarrow la variable es útil
- Si R_{adj}^2 disminuye \rightarrow la variable no aporta información suficiente

Hipótesis sobre un coeficiente:

$$H_0 : \beta_j = 0 \quad \text{vs} \quad H_1 : \beta_j \neq 0$$

Estadístico de contraste:

$$t = \frac{\hat{\beta}_j - 0}{\hat{\sigma}_{\beta_j}} = \frac{\hat{\beta}_j}{\hat{\sigma} \sqrt{(\mathbf{X}^T \mathbf{X})_{jj}^{-1}}} \sim t_{n-p-1}$$

Interpretación:

- **Rechazar** H_0 : La variable X_j es estadísticamente significativa
- **No rechazar** H_0 : No hay evidencia de efecto lineal de X_j sobre Y

Valor p: Probabilidad de observar un estadístico t tan extremo o más, bajo H_0

Intervalo de confianza al $(1 - \alpha)\%$:

$$\hat{\beta}_j \pm t_{\alpha/2, n-p-1} \cdot \hat{\sigma}_{\beta_j}$$

Interpretación:

- Con $(1 - \alpha)\%$ de confianza, el verdadero valor de β_j está en este intervalo
- Si el intervalo **no contiene cero** $\rightarrow \beta_j$ es significativo
- Si el intervalo **contiene cero** $\rightarrow \beta_j$ no es significativo

Relación con el test de hipótesis:

- Intervalo de confianza del 95% \equiv Test de hipótesis con $\alpha = 0.05$
- Si 0 está en el IC del 95% \rightarrow No se rechaza H_0 al 5%

Hipótesis global:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0 \quad \text{vs} \quad H_1 : \text{Al menos un } \beta_j \neq 0$$

Estadístico F:

$$F = \frac{SSR/p}{SSE/(n-p-1)} = \frac{R^2/p}{(1-R^2)/(n-p-1)} \sim F_{p,n-p-1}$$

Interpretación:

- **Rechazar H_0 :** El modelo es globalmente significativo
- **No rechazar H_0 :** El modelo no explica variabilidad significativa

Relación con R^2 : El test F evalúa si R^2 es significativamente diferente de cero

Call:

```
lm(formula = precio ~ superficie + habitaciones + antigüedad +  
    distancia_centro + garaje, data = viviendas)
```

Residuals:

Min	1Q	Median	3Q	Max
-38847	-11074	867	9898	38486

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	53750.97	6666.71	8.063	7.53e-14	***
superficie	1171.78	47.28	24.783	< 2e-16	***
habitaciones	15072.31	1303.42	11.564	< 2e-16	***
antigüedad	-744.59	75.42	-9.872	< 2e-16	***
distancia_centro	-2028.27	164.88	-12.302	< 2e-16	***
garajeSí	25829.43	2349.44	10.994	< 2e-16	***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15950 on 194 degrees of freedom

Multiple R-squared: 0.9094, Adjusted R-squared: 0.9071

F-statistic: 389.4 on 5 and 194 DF, p-value: < 2.2e-16

Predicción puntual: Para un nuevo vector \mathbf{x}_0 :

$$\hat{y}_0 = \mathbf{x}_0^T \hat{\beta}$$

Dos tipos de intervalos:

Intervalo de Confianza:

- Para la **respuesta media** $E[Y|\mathbf{x}_0]$
- Incertidumbre en la estimación
- Más estrecho

Intervalo de Predicción:

- Para una **observación individual** Y_0
- Incertidumbre + variabilidad natural
- Más amplio

Fórmulas: Ambos dependen de $\hat{\sigma}^2$ y de la matriz $(\mathbf{X}^T \mathbf{X})^{-1}$

Intervalo de confianza para la respuesta media:

$$\hat{y}_0 \pm t_{\alpha/2, n-p-1} \cdot \hat{\sigma} \sqrt{\mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

Intervalo de predicción para una observación individual:

$$\hat{y}_0 \pm t_{\alpha/2, n-p-1} \cdot \hat{\sigma} \sqrt{1 + \mathbf{x}_0^T (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{x}_0}$$

Diferencia clave: El “+1” en el intervalo de predicción refleja la variabilidad adicional de una observación individual

Amplitud: Intervalo de predicción > Intervalo de confianza

Una vez ajustado el modelo, es **fundamental realizar un diagnóstico exhaustivo** para verificar que los supuestos se cumplen.

Base del diagnóstico: Análisis de los residuos - nuestra ventana a los errores teóricos no observables

Supuestos a verificar:

1. Normalidad

- Gráfico Q-Q de residuos
- Test de Shapiro-Wilk

2. Independencia

- Residuos vs tiempo
- Test de Durbin-Watson

3. Homocedasticidad

- Gráfico Scale-Location
- Test de Breusch-Pagan

4. Linealidad

- Residuos vs valores ajustados
- **Gráficos CPR** (específicos de múltiple)

Problema: El gráfico residuos vs ajustados puede ocultar una relación no lineal con **una variable específica**

Solución: Gráficos CPR para cada predictor X_j :

$$\text{Residuo Parcial} = e_i + \hat{\beta}_j x_{ij} \quad \text{vs.} \quad x_{ij}$$

Interpretación:






- **Línea sólida:** Relación lineal esperada (pendiente = $\hat{\beta}_j$)
- **Línea punteada:** Suavizado no paramétrico
- **Coincidencia:** Linealidad adecuada
- **Divergencia:** Posible no-linealidad \rightarrow necesita transformación

Ventaja: Permite detectar no-linealidades específicas de cada variable

Ejemplo: Diagnóstico con Gráficos CPR



Gráficos de Componente + Residuo



¿Qué observamos en las 5 variables?

Superficie y Habitaciones:

- Líneas sólida y punteada coinciden
- **Conclusión:** Relación lineal adecuada

Garaje:

- Separación clara entre grupos (No/Sí)
- **Conclusión:** Efecto categórico apropiado

Antigüedad y Distancia:

- Líneas coinciden bien
- **Conclusión:** Linealidad confirmada

Interpretación general:

- Relaciones lineales apropiadas
- No se necesitan transformaciones

Clave: Si las líneas divergen significativamente → considerar transformaciones

¿Qué es? Correlación alta entre variables predictoras

Consecuencias:

1. **Varianza inflada:** Errores estándar muy grandes
2. **Inestabilidad:** Pequeños cambios en datos \rightarrow grandes cambios en coeficientes
3. **Contradicciones:** Modelo globalmente significativo pero ningún predictor individual significativo

Nota importante: La multicolinealidad **NO viola** los supuestos de Gauss-Markov, pero **arruina la interpretación práctica**

Detección:

- **Matriz de correlaciones:** Correlaciones > 0.8 son señal de alerta
- **VIF:** Herramienta definitiva de diagnóstico

Proceso de cálculo del VIF para X_j :

1. Regresar X_j sobre **todas las demás variables predictoras**
2. Obtener el R_j^2 de este modelo auxiliar
3. Calcular:

$$VIF_j = \frac{1}{1 - R_j^2}$$

Interpretación: Factor por el cual se infla la varianza de $\hat{\beta}_j$ debido a multicolinealidad

Reglas prácticas:

- **VIF = 1:** Ausencia de colinealidad (ideal)
- **VIF > 5:** Valores preocupantes que requieren atención
- **VIF > 10:** Multicolinealidad seria que debe ser tratada

Caso 1: Sin problemas de multicolinealidad

superficie	habitaciones	antigüedad
1.40	1.40	1.01

distancia_centro	garaje
1.01	1.01

Caso 2: Con multicolinealidad problemática

superficie_sim	habitaciones_sim	metros_cuadrados
86.4	8.5	81.2

Correlación superficie-metros_cuadrados: 0.994

La estrategia depende del objetivo del análisis:

1. No hacer nada

- Si el objetivo es **predicción**
- Si variables colineales no son de interés

2. Eliminar variables

- Quitar la menos relevante teóricamente
- Mantener la más correlacionada con Y

3. Combinar variables

- Crear índices compuestos
- Análisis de Componentes Principales

4. Métodos alternativos

- **Ridge regression:** Reduce varianza añadiendo sesgo
- **Lasso/Elastic Net:** Regresión penalizada

5. Aumentar muestra

- Más datos pueden reducir correlaciones
- No siempre factible

Conceptos básicos (como en regresión simple):

- **Outlier:** Residuo grande
- **Leverage:** Valor atípico en predictores
- **Influencia:** Impacto en el modelo

Herramientas específicas de regresión múltiple:

DFBETAS: Influencia sobre coeficientes individuales

$$DFBETA_{j,i} = \frac{\hat{\beta}_j - \hat{\beta}_{j(-i)}}{se(\hat{\beta}_{j(-i)})}$$

Criterio: $|extDFBETA_{j,i}| > \frac{2}{\sqrt{n}}$ es problemático

Ventaja: Permite identificar qué observaciones afectan a qué coeficientes específicos

Objetivo: Visualizar la relación entre Y y X_j **después de eliminar el efecto lineal de todos los demás predictores**

Construcción:

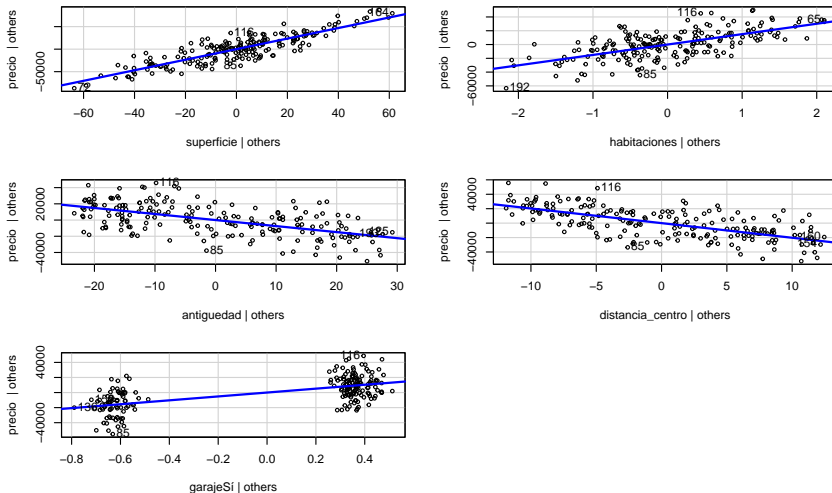
1. Residuos de Y regresado sobre todos los predictores excepto X_j : $e_{Y|X_{-j}}$
2. Residuos de X_j regresado sobre todos los demás predictores: $e_{X_j|X_{-j}}$
3. Graficar: $e_{Y|X_{-j}}$ vs $e_{X_j|X_{-j}}$

Propiedad mágica: La pendiente de la línea ajustada es **exactamente** $\hat{\beta}_j$

Utilidades:

- Visualizar magnitud y significancia del efecto “ajustado”
- Detectar no-linealidades en relaciones parciales
- Identificar observaciones influyentes para coeficientes específicos

Gráficos de regresión parcial



¿Qué vemos en cada gráfico?

- **Eje X:** Residuos de X_j vs. todos los demás predictores
- **Eje Y:** Residuos de Y vs. todos los demás predictores (excepto X_j)
- **Pendiente:** Es exactamente el coeficiente $\hat{\beta}_j$ del modelo múltiple

Interpretación por variable:

- **Superficie:** Relación lineal clara, pendiente positiva
- **Habitaciones:** Relación positiva, algunos puntos influyentes
- **Antigüedad:** Relación negativa evidente
- **Distancia:** Relación negativa clara
- **Garaje:** Separación clara entre grupos (No/Sí)

La regresión múltiple permite:

1. **Efectos parciales:** Aislar el impacto de cada variable predictora
2. **Control de confusores:** Reducir sesgos por variables omitidas
3. **Mejores predicciones:** Incorporar múltiples fuentes de información
4. **Relaciones complejas:** Modelar fenómenos multifactoriales

Aspectos críticos:

- **Interpretación condicional:** Los coeficientes son efectos parciales (*ceteris paribus*)
- **Notación matricial:** Fundamental para la comprensión y computación
- **Supuestos:** Base para las propiedades de los estimadores
- **R^2 ajustado:** Mejor que R^2 para comparar modelos
- **Inferencia:** Tests individuales (t) y global (F)

Próximo paso: Diagnóstico del modelo y tratamiento de problemas específicos